

# Otimização de Carteiras de Fundos com Métodos de Markotiwz e Aprendizado com Reforço

Marcos Carvalho Corrêa Junior <sup>1</sup>  
Rogerio de Oliveira <sup>1</sup>

<sup>1</sup>Faculdade de Computação e Informática (FCI)  
Universidade Presbiteriana Mackenzie São Paulo, SP – Brasil

[<10401844@mackenzista.com.br>](mailto:10401844@mackenzista.com.br)  
[<rogerio.oliveira@mackenzie.br>](mailto:rogerio.oliveira@mackenzie.br)

2025

## 1 Introdução

Nos últimos anos, o crescimento no volume de dados financeiros e a sofisticação dos mercados tornaram a gestão de carteiras uma tarefa cada vez mais complexa. Investidores e gestores precisam lidar com múltiplas variáveis, como volatilidade, correlação entre ativos e eventos macroeconômicos, ao mesmo tempo em que buscam maximizar o retorno ajustado ao risco. Diante desse cenário, surgem oportunidades para o uso de técnicas quantitativas e computacionais que auxiliem na construção de portfólios mais eficientes e adaptados a diferentes contextos de mercado.

A otimização de carteiras é um dos temas centrais da teoria financeira moderna, sendo tradicionalmente abordada por modelos como o de média-variância de Markowitz. No entanto, tais métodos apresentam limitações quando aplicados a ambientes altamente dinâmicos, com múltiplas fontes de incerteza e ativos com comportamentos não lineares. Neste contexto, métodos de aprendizado de máquina — como algoritmos genéticos e aprendizado por reforço — vêm ganhando espaço como alternativas promissoras. O problema de pesquisa que orienta este trabalho é: como o desempenho de modelos baseados em aprendizado de máquina se compara a modelos tradicionais de otimização de carteiras, diante de diferentes conjuntos de dados e métricas de avaliação?

O objetivo geral desta pesquisa é analisar o desempenho de modelos de otimização de carteiras tradicionais e computacionais, com base em dados reais de fundos de investimento listados na B3. Como objetivos específicos, destacam-se: (1) revisar as principais abordagens de otimização de carteiras encontradas na literatura acadêmica; (2) implementar um modelo tradicional com base na Teoria Moderna do Portfólio; (3) desenvolver um modelo baseado em Deep Reinforcement Learning utilizando a biblioteca Gymnasium da OpenAI; e (4)

comparar os resultados obtidos a partir de métricas como retorno acumulado, índice de Sharpe e volatilidade.

Espera-se que os resultados obtidos contribuam tanto para a comunidade acadêmica, ao oferecer uma análise comparativa atualizada entre diferentes paradigmas de otimização de carteiras, quanto para investidores e profissionais de mercado, ao apresentar métodos que podem ser aplicados na prática com o uso de ferramentas computacionais acessíveis. Ao conectar teoria financeira, ciência de dados e programação, esta pesquisa busca fomentar abordagens mais robustas e adaptativas para a tomada de decisão em investimentos.

## 2 Referencial Teórico

A otimização de carteiras de investimento é uma área central da moderna teoria financeira, voltada à alocação eficiente de ativos de modo a maximizar o retorno esperado e minimizar o risco associado. A base teórica clássica desse campo está na Teoria Moderna do Portfólio (Modern Portfolio Theory – MPT), proposta por Harry Markowitz em 1952. Esse modelo estabelece que o risco de um portfólio não deve ser avaliado apenas pela soma dos riscos individuais dos ativos, mas pela correlação entre eles. A função objetivo da MPT consiste em encontrar a combinação ótima de ativos que minimize a variância da carteira para um dado nível de retorno esperado (MARKOWITZ, 1952).

Além da variância, outras métricas de avaliação são amplamente utilizadas, como o índice de Sharpe (SHARPE, 1994), que considera o retorno excedente de uma carteira em relação a um ativo livre de risco, ponderado pela volatilidade. Com o passar dos anos, surgiram também alternativas ao modelo clássico, como a semivariância, o Value-at-Risk (VaR), o Conditional Value-at-Risk (CVaR) e medidas baseadas em drawdown. Embora a MPT tenha sido amplamente aplicada, autores como De Prado (2020) e Loke et al. (2023) destacam que suas limitações — como a instabilidade da matriz de covariância e a dependência de distribuições normais — motivaram a busca por métodos computacionais mais flexíveis e adaptativos.

Nesse contexto, diferentes técnicas de otimização vêm sendo testadas, especialmente com o avanço do poder computacional e o acesso a dados financeiros em grande escala. Entre elas, destacam-se os algoritmos genéticos, redes neurais, aprendizado supervisionado e aprendizado por reforço. No trabalho de Vaneli e Neto (2024), por exemplo, foi utilizado um algoritmo genético para otimizar carteiras com ativos do Ibovespa, alcançando melhores resultados em termos de Índice de Sharpe quando comparado a estratégias tradicionais. Já Melo (2022) aplicou técnicas de Deep Reinforcement Learning para alocação de recursos entre ações e criptoativos, mostrando que o modelo consegue se adaptar dinamicamente às condições de mercado.

A abordagem de Costa (s.d.) combinou pré-seleção de ativos com machine learning (Random Forest, SVR e KNN) e posterior otimização com o modelo de média-variância e Hierarchical Risk Parity. Os resultados demonstraram que essa integração melhora a eficiência das carteiras geradas. Em outra vertente, Tessari (2014) avaliou o impacto da inclusão de fundos imobiliários (FIIs) em carteiras compostas por ações, utilizando os modelos de média-variância e mínima variância, e observou melhora no perfil risco-retorno das carteiras. Souza et al. (2017), por sua vez, aplicaram o modelo de Markowitz com uso do Solver no Excel e constataram que carteiras otimizadas podem superar o desempenho de índices como o Ibovespa em determinados períodos.

Esses trabalhos demonstram a diversidade de abordagens e objetivos presentes na

literatura recente sobre otimização de carteiras. A tendência atual indica uma crescente integração entre modelos matemáticos clássicos e técnicas baseadas em inteligência artificial, reforçando a importância de comparações empíricas como a proposta nesta pesquisa. Ao reunir e confrontar essas metodologias com dados reais, espera-se identificar suas forças e limitações, contribuindo para o avanço das aplicações práticas e teóricas em gestão de investimentos.

### 3 Metodologia

A pesquisa proposta possui caráter aplicado, com abordagem quantitativa e experimental, e baseia-se na comparação entre dois modelos de otimização de carteiras: um tradicional, baseado na Teoria Moderna do Portfólio (Markowitz), e outro baseado em aprendizado por reforço profundo (Deep Reinforcement Learning – DRL). O objetivo é analisar o comportamento e desempenho de ambos os modelos sob diferentes condições de mercado, a partir de dados reais de fundos listados na B3.

A coleta de dados foi realizada por meio da plataforma ComDinheiro e de arquivos disponibilizados pela própria B3 (Brasil, Bolsa, Balcão). A amostragem compreende fundos imobiliários com liquidez relevante e presença contínua no índice IFIX, com séries históricas de preços diários entre 2020 e 2024. Esses dados foram tratados com a linguagem Python, utilizando bibliotecas como Pandas e NumPy para organização, limpeza e padronização das informações.

Após o pré-processamento, os dados foram utilizados em duas abordagens distintas. No modelo tradicional, aplicou-se a técnica de média-variância, com variações envolvendo shrinkage da matriz de covariância e otimizações baseadas em retorno mínimo e máxima razão de Sharpe. A implementação foi feita com a biblioteca PyPortfolioOpt.

Na segunda abordagem, foi implementado um modelo de aprendizado por reforço utilizando a biblioteca Gymnasium, da OpenAI, que permite a construção de ambientes simulados para tomada de decisão sequencial. O agente é treinado para alocar recursos entre os ativos disponíveis, maximizando o retorno acumulado da carteira ao longo do tempo, com base em recompensas derivadas da performance histórica. A rede neural do agente foi construída com TensorFlow, e o algoritmo utilizado para o aprendizado foi o Proximal Policy Optimization (PPO).

Ao final, os dois modelos são comparados com base em métricas como retorno acumulado, volatilidade e Índice de Sharpe, com o objetivo de identificar padrões e contextos nos quais cada abordagem é mais eficiente. Os resultados e gráficos gerados são armazenados em notebooks Jupyter e arquivos estruturados para futura análise estatística.

### 4 Cronograma

Para a conclusão do trabalho no TCC II, a ser realizado no segundo semestre, as atividades foram organizadas da seguinte forma:

Agosto a Setembro: Revisão e aprimoramento dos modelos implementados (Markowitz e DRL), com ajustes no pré-processamento dos dados e nos parâmetros utilizados nos algoritmos. Ampliação do conjunto de ativos e definição de novos recortes temporais para teste.

Setembro a Outubro: Execução dos experimentos com os dois modelos em diferentes cenários. Coleta dos resultados, organização em planilhas, geração de gráficos comparativos e cálculo das métricas de avaliação, como retorno acumulado, volatilidade e Índice de Sharpe.

Outubro a Novembro: Análise dos resultados obtidos, identificação dos pontos fortes e fracos de cada abordagem, e elaboração da discussão comparativa. Início da redação dos capítulos finais do TCC (Resultados, Discussão e Considerações Finais).

Novembro a Dezembro: Finalização do texto, aplicação das correções sugeridas pelo orientador, revisão geral e preparação da apresentação final do trabalho.

Esse cronograma busca assegurar a conclusão completa e estruturada do projeto dentro do semestre, respeitando os prazos institucionais e etapas do desenvolvimento acadêmico.

## Referências

COSTA, T. R. C. C. da. Otimização de portfólio com pré-seleção de ativos usando machine learning: uma aplicação no contexto dos mercados emergentes. *Revista Debates em Economia Aplicada*, v. 2, n. 1, p. 1–27, 2021. S.d.

LOKE, Z. X. et al. Portfolio optimization problem: a taxonomic review of solution methodologies. *IEEE Access*, IEEE, v. 11, p. 33099–33112, 2023.

MARKOWITZ, H. Portfolio selection. *The Journal of Finance*, Wiley, v. 7, n. 1, p. 77–91, 1952.

MELO, F. D. de. *Otimização de portfólio: uma análise através de técnicas de Reinforcement Learning e Autoencoders*. Tese (Dissertação (Mestrado em Ciências)) — Universidade de São Paulo, 2022.

SOUZA, L. C. de; OUTROS. Otimização de carteira de investimentos: Um estudo com ativos do ibovespa. *Revista de Gestão, Finanças e Contabilidade*, v. 7, n. 3, p. 201–213, dez 2017.

VANELI, D. M.; NETO, G. G. *Otimização de Portfólio com Ativos do Ibovespa Usando Algoritmos Genéticos*. 2024. Trabalho de Conclusão de Curso, Instituto Federal do Espírito Santo.